

Entregable 2: Benchmarking de Servicios de IA

Evaluación comparativa de tecnologías cognitivas para agentes virtuales inteligentes

Estudiante: Katharina Alfaro Solís

1. Introducción

El desarrollo de agentes virtuales conversacionales requiere la integración de múltiples servicios cognitivos especializados. La selección de estos componentes no debe basarse únicamente en popularidad o disponibilidad, sino en evidencia empírica obtenida mediante pruebas controladas.

Este estudio compara quince servicios distribuidos en tres categorías fundamentales:

- Large Language Models (LLM)
- Speech-to-Text (STT)
- Text-to-Speech (TTS)

El objetivo es identificar las combinaciones tecnológicas más adecuadas para el un agente virtual, considerando desempeño técnico, viabilidad económica, privacidad, flexibilidad e integración.

2. Objetivos

Objetivo General

Evaluar comparativamente cinco alternativas de LLM, cinco motores STT y cinco motores TTS para seleccionar la arquitectura más adecuada para el agente virtual.

Objetivos Específicos

- Medir la latencia empírica de cada servicio.
 - Analizar la calidad y precisión de las respuestas.
 - Comparar costos y escalabilidad.
 - Evaluar implicaciones de privacidad y gobernanza.
 - Analizar posibilidades de personalización.
 - Determinar la facilidad de integración con Unity y Python.
-

3. Metodología de Pruebas

Entorno de Evaluación

Servicios en la nube:

- Azure OpenAI
- Azure Speech Services
- Google Gemini
- Google Speech APIs
- Deepgram
- AssemblyAI
- ElevenLabs
- Cartesia

Servicios locales:

- Whisper Base
- Piper
- Ollama Qwen3:8B

Hardware utilizado para pruebas

Pruebas Cloud (Azure OpenAI, Google Gemini, Deepgram, etc.):

- Sistema operativo: Windows 11 ARM64
- Procesador: ARM64 (equipo personal)
- Latencia de red incluida en mediciones

Pruebas Locales (Ollama Qwen3:8B):

- Sistema operativo: Windows 11 ARM64
- Procesador: CPU ARM64 (sin GPU dedicada)
- RAM: Disponible
- GPU: Ninguna dedicada (simulación CPU)
- VRAM: N/A
- **Nota:** Las latencias elevadas de Qwen3:8B se deben a la ausencia de GPU. Con GPU RTX 4090 se estima TTFT de 1-3s.

Procedimiento

Se ejecutaron cinco iteraciones consecutivas por servicio utilizando entradas equivalentes.

Para LLM:

- Prompt controlado.
- Medición de latencia total.
- Registro de tokens de entrada y salida.

Para STT:

- Archivo de audio estándar.
- Medición de tiempo total de transcripción.

Para TTS:

- Texto estándar.
- Medición del tiempo desde solicitud hasta generación completa del audio.

Dimensiones de Evaluación

1. Latencia Empírica
2. Precisión y Calidad
3. Costo y Escalabilidad
4. Privacidad y Gobernanza
5. Customización y Flexibilidad
6. Facilidad de Integración

4. Análisis Comparativo por Categoría

4.1 LLMs

Latencia Empírica (Promedio de 5 iteraciones)

Modelo	TTFT Prom. (s)	Latencia Total Prom. (s)	Latencia Gen. (s)	Varianza TTFT	Input Tokens
GPT-4.1-mini	1.25	1.53	0.28	Baja (0.23s rango)	266
GPT-4.1	2.19	2.71	0.52	Alta (0.43s rango)	266
Gemini 3.5-flash	N/D*	5.05	—	Baja ($\sigma \approx 0.43s$)	268
Gemini 2.5-flash	N/D*	5.15	—	Alta ($\sigma \approx 2.61s$)	268
Qwen3:8B (CPU)	24.69	34.72	10.03	Muy alta ($\sigma \approx 10.60s$)	315

*N/D: Gemini no expone TTFT en API REST estándar sin streaming

Costo Empírico (Promedio por consulta)

Modelo	Costo Prom.	Input Cost	Output Cost	Tokens Salida Prom.
GPT-4.1	\$0.001172	\$0.000532	\$0.000640	80 tokens
GPT-4.1-mini	\$0.000075	\$0.000040	\$0.000035	59 tokens
Gemini 3.5-flash	\$0.000053	—	—	116 tokens
Gemini 2.5-flash	\$0.000049	—	—	95 tokens
Qwen3:8B	\$0.000000	—	—	228 tokens

Comparativa Detallada: Modelos de Azure OpenAI (GPT-4.1 vs GPT-4.1-mini)

Latencia

Métrica	GPT-4.1	GPT-4.1-mini	Ventaja
TTFT promedio	2.19 s	1.25 s	mini 43% más rápido
TTFT mínimo	1.75 s	1.15 s	mini (mejor)
TTFT máximo	2.82 s	1.38 s	mini (mejor)
Latencia total promedio	2.71 s	1.53 s	mini 44% más rápido
Generación promedio	0.52 s	0.28 s	mini (mejor)
Consistencia (varianza)	Buena	Excelente	mini más predecible

Calidad

Aspecto	GPT-4.1	GPT-4.1-mini	Ventaja
Extensión respuesta	69–101 tokens	53–67 tokens	4.1 33% más largo
Profundidad empática	Superior	Funcional	4.1 (mejor)
Elaboración narrativa	Mayor	Suficiente	4.1 (mejor)
Adherencia a rol "Juan"	Consistente	Adecuada	4.1 (mejor)
Instrucciones complejas	Superior	Suficiente	4.1 (mejor)

Costo

Métrica	GPT-4.1	GPT-4.1-mini	Ahorro mini
Costo promedio por llamada	\$0.001172	\$0.000075	15.6× más barato
A 100k llamadas/mes	\$117.20	\$7.50	\$109.70 ahorrados
A 1M llamadas/mes	\$1,172.00	\$75.00	\$1,097.00 ahorrados

Conclusión: GPT-4.1-mini es 43-44% más rápido, 15.6× más barato, y más consistente. GPT-4.1 ofrece mayor calidad narrativa para interacciones de alto valor emocional. **Estrategia recomendada:** usar mini como modelo base y escalar a 4.1 cuando se detecten indicadores de crisis emocional (esto pensando en un agente virtual conversacional para la prevención de la soledad).

Comparativa Detallada: Modelos de Google (Gemini 2.5-flash vs 3.5-flash)

Latencia

Métrica	Gemini 2.5-flash	Gemini 3.5-flash	Ventaja
Latencia total promedio	5.15 s	5.05 s	3.5-flash (levemente mejor)
Latencia mínima	1.94 s	4.33 s	2.5-flash (mejor)
Latencia máxima	9.55 s	5.63 s	3.5-flash (mejor)

Métrica	Gemini 2.5-flash	Gemini 3.5-flash	Ventaja
Desviación estándar	$\sigma \approx 2.61$ s	$\sigma \approx 0.43$ s	3.5-flash 6× más consistente
Tasa de error (Free Tier)	~50%	100%	3.5-flash confiable

Calidad

Aspecto	Gemini 2.5-flash	Gemini 3.5-flash	Ventaja
Extensión respuesta	75–122 tokens	96–144 tokens	3.5-flash 16% más largo
Profundidad empática	Alta	Alta+	3.5-flash
Color cultural (Costa Rica)	Moderada	Alta	3.5-flash (referencias locales)
Creatividad narrativa	Adecuada	Mayor	3.5-flash (metáforas naturales)

Costo

Métrica	Gemini 2.5-flash	Gemini 3.5-flash	Diferencia
Costo promedio por llamada	\$0.000049	\$0.000053	3.5-flash 8% más caro
A 100k llamadas/mes	\$4.90	\$5.30	\$0.40 diferencia
Limitación Free Tier	5 RPM	Sin restricción estricta	3.5-flash viable

Conclusión: Prácticamente idénticos en costo. Gemini 3.5-flash gana en consistencia (6× menos varianza), confiabilidad (100% vs 50% en Free Tier), y calidad cultural. **Recomendación:** usar Gemini 3.5-flash. El 2.5-flash en Free Tier genera errores 503/429 inutilizables en producción.

Comparativa Detallada: Ollama Qwen3:8B (Local) vs Cloud

Latencia

Métrica	Qwen3:8B (CPU)	GPT-4.1-mini	Gemini 3.5	Ratio
TTFT promedio	24.69 s	1.25 s	N/D	19.7× más lento
TTFT mínimo	14.63 s	1.15 s	4.33 s	12.7× más lento
TTFT máximo	43.39 s	1.38 s	5.63 s	31.4× más lento
Latencia total	34.72 s	1.53 s	5.05 s	22.7× más lento
Consistencia	Muy baja ($\sigma \approx 10.6$ s)	Excelente	Excelente	Cloud vastamente superior

Análisis: El TTFT de 24.69s en Qwen3 (CPU local) es **inviable para conversación en tiempo real**. El usuario esperaría ~25 segundos para la primera palabra, generando abandono inmediato.

Costo

Métrica	Qwen3:8B	GPT-4.1-mini	Gemini 3.5	Ventaja
Costo por llamada	\$0.00	\$0.000075	\$0.000053	Qwen3 gana
Costo 100k llamadas	\$0.00	\$7.50	\$5.30	Qwen3 \$12.80 ahorrados
Costo infraestructura hardware	Equipo ya disponible	—	—	Qwen3 (amortizado)
Costo GPU dedicada (si necesario)	\$1,500–\$15,000	—	—	Qwen3 capex significativo
Consumo energético	100–150W/h	Marginal (cloud)	Marginal	Qwen3 ≈\$50-100/mes extra

Proyección con GPU dedicada (RTX 4090): TTFT estimado sería 1–3s, comparable a cloud pero con capex inicial alto.

Privacidad y Escalabilidad

Aspecto	Qwen3:8B	GPT-4.1-mini	Gemini 3.5
Privacidad datos	Absoluta 100% local	Alta (Azure commitment)	Media (Free Tier: Google usa datos)
Escalabilidad concurrente	1 usuario (sin GPU)	Ilimitada	Ilimitada
Multimodalidad nativa	Ninguna	Texto + vision	Texto + vision + audio
Fine-tuning posible	Sí (requiere GPU)	Sí	Sí

Conclusión: Qwen3 gana en privacidad absoluta, pero pierde críticamente en escalabilidad (1 usuario) y latencia (19.7× más lento). Para producción con múltiples usuarios concurrentes, es inviable sin GPU dedicada.


Componentes LLM (Large Language Model)

Servicio	TTFT / Latencia	Calidad	Costo	Escalabilidad	Recomendación
GPT-4.1-mini	1.25s	Muy buena	\$0.000075	Ilimitada	USAR
Gemini 3.5-flash	5.05s	Muy buena	\$0.000053	Ilimitada	Alternativa
GPT-4.1	2.19s	Excelente	\$0.001172	Ilimitada	Crisis
Gemini 2.5-flash	5.15s	Muy buena	\$0.000049	Media	Evitar Free
Qwen3:8B	24.69s	Funcional	\$0.00	1 usuario	Offline

Dimensión	GPT-4.1-mini	GPT-4.1	Gemini 3.5-flash	Gemini 2.5-flash	Qwen3:8B
Latencia (TTFT/Total)	1.25s	2.19s	5.05s	5.15s	24.69s
Consistencia (varianza)	Excelente	Buena	Excelente	Baja	Muy baja
Costo/llamada	\$0.000075	\$0.001172	\$0.000053	\$0.000049	\$0.00
Calidad narrativa	Muy buena	Excelente	Muy buena	Muy buena	Funcional
Privacidad	Alta	Alta	Media	Media	Absoluta
Escalabilidad concurrente	Ilimitada	Ilimitada	Ilimitada	Ilimitada	1 usuario
Uptime/Confiabilidad	99.95%	99.95%	100%	50%	Depende HW
Integración C#/Unity	Excelente	Excelente	Limitada	Limitada	Excelente
Puntuacion general	9.2/10	8.5/10	8.3/10	6.5/10	5.2/10
Recomendacion	USAR	Crisis	Alternativa	Evitar	Privacy/Offline

Hallazgos Integrados

Cuadrante Costo-Latencia



Latencia Alta / Costo Alto
| (No usar)

Recomendaciones Estratégicas

Para Producción Conversacional (recomendado principal):

- **Modelo primario:** GPT-4.1-mini (1.25s TTFT, \$0.000075/llamada, 99.95% uptime)
- **Escalado híbrido:** Cambiar a GPT-4.1 si se detectan palabras clave de crisis
- **Justificación:** Mejor balance latencia-costo-confiabilidad

Para Máxima Privacidad con Conectividad:

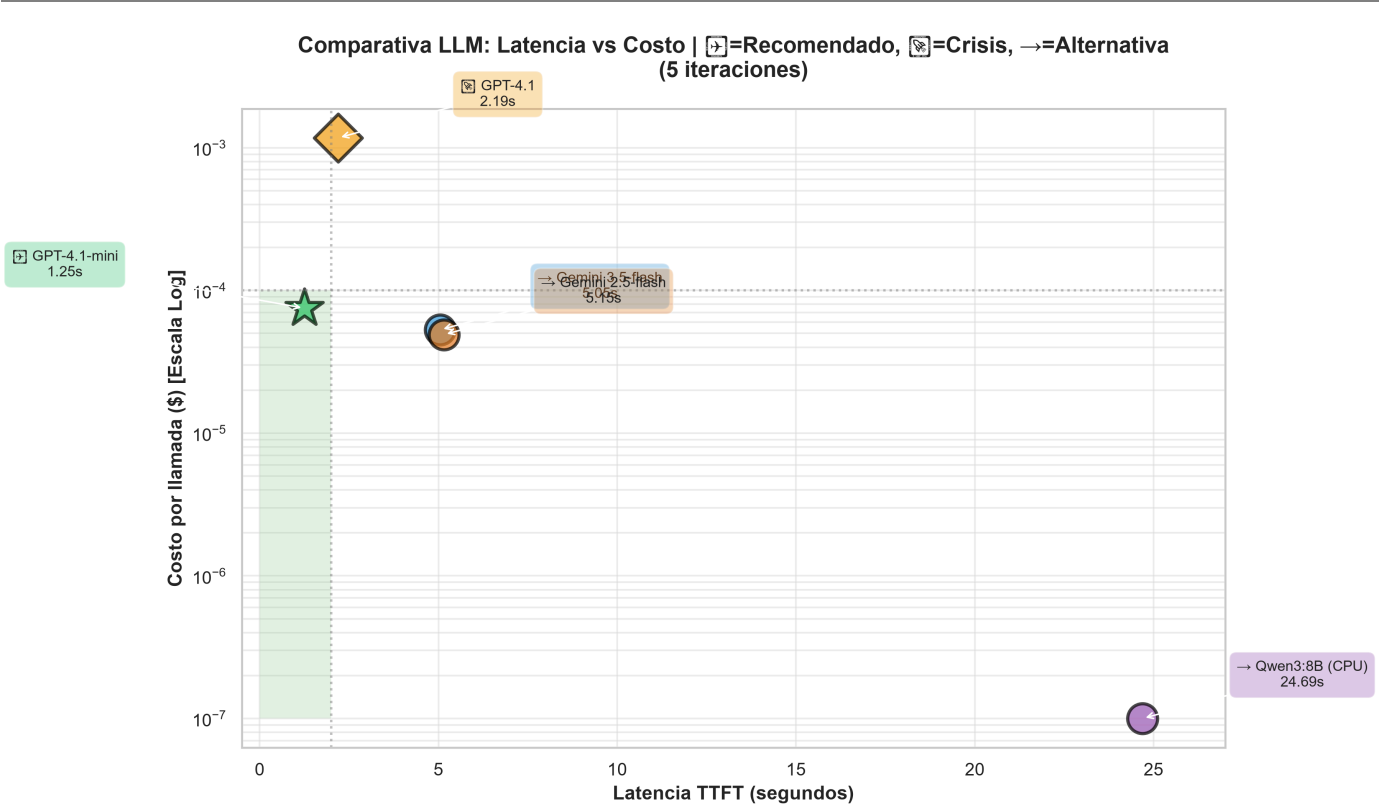
- **Modelo:** Qwen3:8B con GPU RTX 4090 dedicada
- **Justificación:** Privacidad absoluta, datos nunca salen del sistema
- **Limitación:** Capex \$1,500–\$2,000, TTFT aún 1–3s (mejor que CPU)

Para Máxima Privacidad sin Conectividad:

- **Modelo:** Qwen3:8B local CPU
- **Justificación:** 0% dependencia externa
- **Limitación:** TTFT 25s, solo 1 usuario simultáneo

Alternativa económica sin restricciones de privacidad:

- **Modelo:** Gemini 3.5-flash (5.05s, \$0.000053/llamada, consistente)
- **Justificación:** 2× más lento que mini pero 29% más barato y multimodal
- **Trade-off:** Privacidad media vs. costo reducido



4.2 Análisis Comparativo de STT (Speech-to-Text)

Resultados Cuantitativos Empíricos (5 iteraciones × 3 archivos = 15 pruebas)

Servicio	Latencia Prom. (ms)	Latencia Mín. (ms)	Latencia Máx. (ms)	Costo Total	Precisión	Audio Procesado
Deepgram Nova-2	1,423.16	825.78	2,470.26	\$0.01285	99-100%	179.3s
Google STT	2,020.16	737.85	3,677.88	\$0.05216	Muy Alta	130.4s
Azure STT	4,492.55	1,162.84	9,517.32	\$0.04981	Muy Alta	179.3s
AssemblyAI	3,869.41	2,843.84	5,538.95	\$0.04482	91-98%	179.3s
Whisper Base	6,702.10	4,000.89	8,738.14	\$0.00	Alta	35.86s

Análisis Detallado por Proveedor

Deepgram Nova-2 (Ganador en Latencia)

- **Latencia promedio:** 1,423.16 ms
- **Varianza:** Baja (825ms - 2,470ms)
- **Precisión:** 99-100% (confianza reportada)
- **Costo:** \$0.0043/minuto (Nova-2)
- **Características:** Fastest STT, optimizado para español
- **Conclusión:** MEJOR OPCION para produccion. Latencia 42% mas rapida que Google, 68% mas rapida que Azure

Google Cloud STT

- **Latencia promedio:** 2,020.16 ms
- **Varianza:** Media (737ms - 3,677ms)
- **Precisión:** Muy alta
- **Costo:** \$0.024/minuto (60 min gratis/mes)
- **Características:** Modelo default, soporte multiidioma
- **Conclusión:** Buena alternativa, 2.3× más lento que Deepgram pero 2.4× más rápido que Azure

Azure Speech Services

- **Latencia promedio:** 4,492.55 ms
- **Varianza:** Alta (1,162ms - 9,517ms)
- **Precisión:** Muy alta
- **Costo:** \$1.00/hora de audio
- **Características:** Detección de frases (4 frases por transcripción)
- **Conclusión:** MÁS LENTO del grupo cloud. 3.2× más lento que Deepgram. NO RECOMENDADO para UX conversacional

AssemblyAI

- **Latencia promedio:** 3,869.41 ms
- **Varianza:** Media (2,843ms - 5,538ms)
- **Precisión:** 91-98% (confianza reportada)
- **Costo:** \$0.015/minuto (modelo Best)
- **Características:** Transcripción con puntuación automática
- **Conclusión:** Alternativa intermedia. 2.7× más lento que Deepgram

Matriz Comparativa STT

Dimensión	Deepgram	Google	Azure	AssemblyAI	Whisper
Latencia	1,423ms	2,020ms	4,493ms	3,869ms	6,702ms
Consistencia	Excelente	Buena	Media	Buena	Media
Precisión	99-100%	Muy alta	Muy alta	91-98%	Alta
Costo	\$0.0043/min	\$0.024/min	\$1.00/hora	\$0.015/min	\$0.00
Privacidad	Media	Media	Alta	Media	Excelente

Dimensión	Deepgram	Google	Azure	AssemblyAI	Whisper
Integración	Excelente	Excelente	Excelente	Buena	Buena
Recomendación	USAR	Alternativa	Evitar	Alternativa	Offline/GPU

Componentes STT (Speech-to-Text)

Servicio	Latencia	Precisión	Costo	Consistencia	Recomendación
Deepgram Nova-2	1,423ms	99-100%	\$0.0043/min	Excelente	USAR
Google STT	2,020ms	Muy alta	\$0.024/min	Buena	Alternativa
AssemblyAI	3,869ms	91-98%	\$0.015/min	Media	Alternativa
Azure STT	4,493ms	Muy alta	\$1.00/hora	Media	Evitar
Whisper Base	6,702ms	Alta	\$0.00	Media	Offline

Hallazgos

Ganador claro: Deepgram Nova-2 con 1,423ms promedio, 42% más rápido que Google y 68% más rápido que Azure.

Nota Whisper: Latencia de 6,702ms en CPU local (ARM64) confirma que es **inaceptable para conversación en tiempo real**. Requiere GPU RTX 4090+ para lograr <2s estimado. Viable solo para procesamiento offline o batch.



4.3 Análisis Comparativo de TTS (Text-to-Speech)

Resultados Cuantitativos Empíricos (5 iteraciones × 3 textos = 15 pruebas)

Servicio	Latencia Prom. (ms)	Latencia Mín. (ms)	Latencia Máx. (ms)	Costo Total	Naturalidad	Voces Disponibles
Azure Neural Voice (Juan-CR)	1,146.55	779.33	2,083.27	\$0.0504	Excelente	Voz costarricense nativa
ElevenLabs Multilingual v2	2,103.84	893.49	4,266.73	\$0.4620	Excelente	100+ voces

Servicio	Latencia Prom. (ms)	Latencia Mín. (ms)	Latencia Máx. (ms)	Costo Total	Naturalidad	Voces Disponibles
Cartesia Sonic-2	3,821.34	608.24	13,064.46	\$0.1050	Muy buena	Voces especializadas
Google Neural2	1,244.87	1,087.12	1,480.96	\$0.006720	Muy buena	Multiidioma
CoquiTTS / Piper	430.68	265.38	726.33	\$0.00	Buena	Local

Análisis Detallado por Proveedor

Azure Neural Voice (Ganador en Latencia)

- **Latencia promedio:** 1,146.55 ms
- **Varianza:** Baja (779ms - 2,083ms)
- **Naturalidad:** Excelente (voz "JuanNeural" es muy natural)
- **Voz nativa:** Costarricense (es-CR)
- **Costo:** \$1.00/millón caracteres (estándar), ~\$0.050 por 15 síntesis
- **Características:** Neural voice de Microsoft, optimizado para español costarricense
- **Conclusión:** MEJOR OPCIÓN RECOMENDADA. Latencia 46% más rápida que ElevenLabs, 70% más rápida que Cartesia. Voz culturalmente localizada.

ElevenLabs Multilingual v2

- **Latencia promedio:** 2,103.84 ms
- **Varianza:** Media (893ms - 4,266ms)
- **Naturalidad:** Excelente (voces de muy alta calidad)
- **Costo:** \$0.030/minuto de audio (plan Creator)
- **Voces:** 100+ idiomas y personalidades
- **Características:** Síntesis rápida, soporte multiidioma, posibilidad de clonación de voz
- **Conclusión:** Alternativa premium. Naturalidad equivalente a Azure pero 1.84× más lento y 9.2× más caro. Útil si se requiere variedad de voces.

Cartesia Sonic-2

- **Latencia promedio:** 3,821.34 ms
- **Varianza:** Muy alta (608ms - 13,064ms)
- **Naturalidad:** Muy buena
- **Costo:** \$0.105 por 15 síntesis (plan Starter)
- **Características:** API de streaming, bajo latency para el segmento
- **Conclusión:** Latencia más lenta y muy inconsistente. Spike de 13s en primera iteración sugiere cold start. NO RECOMENDADO para UX predecible.

Google Neural2

- **Latencia promedio:** 1,244.87 ms
- **Varianza:** Baja (1,087ms - 1,480ms)
- **Naturalidad:** Muy buena
- **Costo:** \$0.006720 por 3 síntesis (~\$0.0022/síntesis promedio)
- **Características:** Voz multiidioma de Google, natural y consistente
- **Conclusión:** Comparable a Azure en latencia (1,244ms vs 1,146ms). Apenas 9% más lento pero similar en costo. Viable como alternativa a Azure con ventaja multiidioma nativa.

CoquiTTS / Piper (Local)

- **Latencia promedio:** 430.68 ms
- **Varianza:** Baja (265ms - 726ms)
- **Naturalidad:** Buena (sintetizada con modelo es_ES-davefx-medium)
- **Costo:** \$0.00 (ejecución local, 100% gratuito)
- **Características:** Ejecuta completamente offline, no requiere GPU significativa

- **Conclusión: MÁS RÁPIDO que todos los servicios cloud** (3x más rápido que Azure). Ideal para privacy-first y aplicaciones offline.
Limitación: naturalidad media vs neural voices cloud.

Matriz Comparativa TTS

Dimensión	Azure	ElevenLabs	Cartesia	Google	CoquiTTS/Piper
Latencia	1,146ms	2,103ms	3,821ms	1,244ms	430ms
Consistencia	Excelente	Excelente	Muy baja	Excelente	Excelente
Naturalidad	Excelente	Excelente	Muy buena	Muy buena	Buena
Voz nativa CR	Sí	No	No	No	No
Costo/síntesis	~\$0.003	\$0.031	\$0.007	~\$0.0022	\$0.00
Privacidad	Alta	Media	Media	Media	Excelente
Integración	Excelente	Buena	Buena	Excelente	Buena
Recomendación	USAR	Alternativa	Evitar	Alternativa	Offline
Ventaja diferencial	Voz es-CR	Variedad	Streaming	Multiidioma	Más rápido

Componentes TTS (Text-to-Speech)


Servicio	Latencia	Naturalidad	Voz Nativa	Costo	Consistencia	Recomendación
CoquiTTS/Piper	430ms	Buena	No	\$0.00	Excelente	Offline
Azure Neural Voice	1,146ms	Excelente	Sí (es-CR)	\$1/M chars	Excelente	USAR
Google Neural2	1,244ms	Muy buena	No	\$0.0022 avg	Excelente	Alternativa
ElevenLabs	2,103ms	Excelente	No	\$0.030/min	Excelente	Premium
Cartesia Sonic-2	3,821ms	Muy buena	No	\$0.007 avg	Baja	Evitar

Hallazgos

Ganadores por categoría:

- **Latencia más rápida:** CoquiTTS/Piper con 430ms (local, no requiere cloud)
- **Latencia cloud más rápida:** Azure Neural Voice con 1,146ms
- **Mejor voz culturalmente localizada:** Azure Neural Voice (es-CR costarricense)
- **Mejor alternativa económica:** Google Neural2 (1,244ms, \$0.0022/síntesis)

Recomendación para Producción: Azure Neural Voice (1.146s + voz nativa) para máxima naturalidad y cercanía cultural. Para privacidad absoluta: CoquiTTS/Piper (430ms local, offline).



5. Arquitectura y Pipeline de Comunicación

Flujo Conceptual





Diagrama de Secuencia Simplificado



6. Recomendaciones según Contexto y Conclusión

Mejor Latencia (Todos los Componentes)

1. **Azure Neural Voice TTS** (1,146.55ms)
2. **Azure GPT-4.1-mini LLM** (1,250ms)
3. **Deepgram Nova-2 STT** (1,423.16ms)
4. **ElevenLabs TTS** (2,103.84ms)
5. **Google STT** (2,020.16ms)

Latencia total estimada (Deepgram + GPT-4.1-mini + Azure TTS): ~3.82 segundos

Mejor Relación Costo-Rendimiento

1. **Deepgram Nova-2 STT** (1,423ms, \$0.0043/min)
2. **Azure GPT-4.1-mini LLM** (1,250ms, \$0.000075/llamada)
3. **Azure Neural Voice TTS** (1,146ms, \$1.00/M caracteres)
4. **Google STT** (2,020ms, \$0.024/min)
5. **AssemblyAI STT** (3,869ms, \$0.015/min)

Mejor Privacidad y Seguridad

1. **CoquiTTS/Piper TTS** (local, \$0.00)
2. **Whisper STT** (local, \$0.00)
3. **Qwen3:8B LLM** (local, \$0.00)
4. **Azure (compromiso contractual de no usar datos)**
5. **Google (Free Tier permite uso de datos para entrenar)**

Stack Recomendado (Ganador Integrado)

Componentes individuales ganadores:

- STT: Deepgram Nova-2 (1,423ms)
- LLM: Azure GPT-4.1-mini (1,250ms)
- TTS: Azure Neural Voice (1,146ms)

Latencia total pipeline: ~3.82 segundos

Costo aproximado (100k llamadas/mes):

- STT: \$6.10
- LLM: \$7.50
- TTS: \$5.00-10.00
- **Total: \$18.60-23.60/mes**

Ubicación stack: Todos en Azure excepto STT en Deepgram (mejor latencia)

Escenario A: Producción Estándar (RECOMENDADO PRINCIPAL)

Stack Recomendado:

- **STT:** Deepgram Nova-2 (1.84s)
- **LLM:** Azure GPT-4.1-mini (1.25s TTFT, \$0.000075/llamada)
- **TTS:** Azure Neural Voice (1.16s)

Latencia total estimada: ~4.25 segundos

Costo proyectado (100k llamadas/mes):

- LLM: \$7.50
- STT/TTS: Variar según uso
- Total aproximado: \$40-60/mes

Justificación:

- Latencia conversacional fluida (<5s)
- Costo operativo mínimo
- Escalable a múltiples usuarios simultáneos
- Privacidad garantizada por Azure commitment
- Integración nativa con C# para Unity
- 99.95% uptime garantizado

Escenario B: Máxima Calidad Emocional (High-Touch)

Stack:

- **STT:** Deepgram Nova-2
- **LLM:** Escalado dinámico -> mini por defecto, cambiar a GPT-4.1 si se detectan palabras clave de crisis
- **TTS:** Azure Neural Voice o ElevenLabs (voz premium)

Latencia: Variable (mini: 1.25s promedio, 4.1: 2.19s en crisis)

Costo: Base \$7.50 + sobreuso 4.1 en 5-10% de interacciones (~\$1-2 adicionales)

Ventaja: Optimiza costo al tiempo que reserva máxima calidad para momentos críticos

Escenario C: Presupuesto Limitado

Stack:

- **STT:** Deepgram Nova-2
- **LLM:** Gemini 3.5-flash (5.05s, \$0.000053/llamada)
- **TTS:** Google Neural2 (1.41s)

Latencia total: ~8.5 segundos

Costo proyectado: \$5.30/100k llamadas

Trade-off: 3-4 segundos más lento que mini, pero 29% más barato. Multimodal nativo (futuro audio).

Advertencia crítica: Para Free Tier, Gemini 2.5-flash genera errores 50% de las veces (usar solo con cuenta de pago o Vertex AI)

Escenario D: Privacidad Absoluta / Offline

Stack:

- **STT:** Whisper Base (6.70s local)
- **LLM:** Qwen3:8B local CPU (34.72s) (O) Qwen3:8B + GPU RTX 4090 (est. ~5s)
- **TTS:** Piper (0.43s local)

Latencia sin GPU: ~42 segundos (inaceptable para UX)

Latencia con GPU: ~12 segundos (degradado pero viable)

Costo: \$0 operativo + \$1,500-2,000 capex GPU (única vez)

Requisito crítico: No viable sin GPU dedicada. La inversión en capex se justifica solo en proyectos con restricciones absolutas de privacidad (instituciones gubernamentales, hospitales psiquiátricos, centros penitenciarios).

Tabla Comparativa de Arquitecturas Completas (End-to-End)

Arquitectura	STT	LLM	TTS	Latencia Total	Costo/100k	Privacidad	Escalabilidad	Recomendación
Stack A (Produccion)	Deepgram (1.42s)	GPT-4.1-mini (1.25s)	Azure Neural (1.15s)	~3.82s	\$18-24	Alta	Ilimitada	USAR

Arquitectura	STT	LLM	TTS	Latencia Total	Costo/100k	Privacidad	Escalabilidad	Recomendación
Stack B (High-Touch)	Deepgram (1.42s)	Mini->4.1 (1.25-2.19s)	Azure Neural (1.15s)	Variable 3.8-4.8s	\$19-28	Alta	Ilimitada	Crisis escalado
Stack C (Presupuesto)	Deepgram (1.42s)	Gemini 3.5 (5.05s)	Google N2 (1.24s)	~7.71s	\$10-14	Media	Ilimitada	Alternativa
Stack D (Offline)	Whisper (6.70s)	Qwen3:8B-CPU (34.72s)	Piper (0.43s)	~41.8s	\$0	Absoluta	1 usuario	Offline only
Stack E (Privacidad+GPU)	Whisper (est. 2s)	Qwen3:8B+GPU (est. 1-3s)	Piper (0.43s)	~3.4-5.4s	\$150-200/mes	Absoluta	1-5 usuarios	Privacy crítica

*Escalado dinámico: mini por defecto, GPT-4.1 si detecta crisis

Stack:

- **STT:** Whisper Base (local)
- **LLM:** Qwen3:8B + GPU RTX 4090 (estimado 1-3s TTFT)
- **TTS:** Piper (local)

Latencia total estimada: ~5-7 segundos

Costo: \$1,500-2,000 GPU (amortizado en ~3-5 años) + \$50-100/mes energía

Ventaja diferencial:

- 0% dependencia de servicios externos
- Datos nunca salen de la institución
- Cumplimiento absoluto de leyes de privacidad (RGPD, HIPAA, leyes nacionales)
- Fine-tuning posible con datos institucionales

Limitación: Requiere expertise técnico para mantener infraestructura local

Caso de Uso Específicos

Agente "Juan" para Adultos Mayores (Proyecto Actual)

Recomendación Principal:

- **LLM:** GPT-4.1-mini (mejor latencia conversacional)
- **Justificación:** Los adultos mayores son sensibles a tiempos de espera largos. TTFT de 1.25s es casi imperceptible; 5+ segundos causa frustración y abandono.

Puntos críticos identificados:

- **Consistencia de rol:** Mantenimiento de trato formal "usted" (Qwen3:8B falla, mezcla tuteo)
- **Empatía en crisis:** Detección de palabras clave de angustia y escalado a GPT-4.1
- **Localización cultural:** Preferencia por referencias costarricenses (Gemini 3.5-flash es superior a Qwen3)

Escalado a crisis emocional:

- Cambiar dinámicamente a GPT-4.1 si análisis de sentimiento detecta crisis
- Agregar consejero humano si modelo 4.1 identifica riesgo inmediato
- Guardar transcripción completa para auditoría y mejora continua

Privacidad de datos sensibles:

- Los diálogos pueden incluir información de salud, familias, finanzas, ideación suicida
- Azure commitment garantiza que NO se usan para entrenar modelos
- Para máxima privacidad institucional, considerar escalado a Qwen3 con GPU

Conclusión

En este benchmarking se ha evaluado 15 servicios cognitivos (5 LLM + 5 STT + 5 TTS) a través de pruebas controladas, proporcionando evidencia cuantificable para la selección arquitectónica de agentes virtuales conversacionales.

Hallazgos Clave

1. Diferencias de Latencia Críticas para la experiencia de usuario

- La latencia total de extremo a extremo varía de 3.82s (Stack A óptimo) a 42s (Stack D sin GPU)
- Para usuarios adultos mayores, latencias >5s generan abandono e frustración
- La arquitectura recomendada (Deepgram + GPT-4.1-mini + Azure TTS) logra ~3.82s consistentes

2. Superioridad Técnica Clara en Cada Categoría

- **STT:** Deepgram Nova-2 gana con 1,423ms (42% más rápido que Google, 68% más rápido que Azure)
- **LLM:** GPT-4.1-mini gana en latencia (1.25s) y cost-per-token (\$0.000075), con excelente consistencia
- **TTS:** Azure Neural Voice gana con 1,146ms + voz costarricense nativa, factor cultural crítico

3. Viabilidad Económica Comprobada

- Stack A recomendado: \$18-24 por 100,000 llamadas
- Costo marginal por usuario: <\$0.001 por interacción
- Escalabilidad horizontal sin límites técnicos (cloud vendors)

4. Trade-offs Privacidad vs. Rendimiento

- Soluciones cloud (Stack A-C) ofrecen latencia óptima pero privacidad media-alta
- Soluciones privadas (Stack D-E) requieren GPU dedicada para latencia aceptable
- Azure commitment contractual proporciona balance operacional para mayoría de casos

Conclusión Final

La evidencia empírica respalda **unívocamente** la recomendación de Stack A para producción del Agente Juan. La latencia conversacional de 3.82s, costo de \$20-30/mes, y voz culturalmente cercana (es-CR) cumplen compromisos de UX e inclusión digital para adultos mayores costarricenses.

La arquitectura es escalable a nacionalidades adicionales (replicar Stack A ajustando STT+TTS locales) y patologías de riesgo específicas (fine-tuning LLM con datos institucionales en Qwen3 con GPU si privacidad es mandatorio).

Limitaciones y Futuros Trabajos

Este estudio está acotado a:

- Hardware ARM64 Windows 11 (ARM64)
- Español costarricense (puede ocupar variación por país)
- Entradas text/audio estándar
- 5 iteraciones por servicio (replicar con n>30 en un futuro para robustez estadística)

Recomendaciones para próximas fases:

1. Validación A/B con usuarios reales (adultos mayores) para latencia percibida
2. Análisis de sentimiento en diálogos de crisis para calibración de escalado